

Phân Tích Nguy Cơ Ung Thư TUYẾN Giáp: Khám Phá & Suy Luận Dữ Liệu Dữ

- **Cỡ mẫu:** 150,500 quan sát y tế
- **Bộ dữ liệu:** Thyroid Cancer Risk (Đã chuẩn hóa)
- **Môn học:** INT3425 - Khoa học Dữ liệu

Sinh viên: Bùi Đình Cảnh - 24021392 - Mức độ đóng góp: 60%



Sinh viên: Trần Đức Anh - 24021376 - Mức độ đóng góp: 40%

Đặc Trưng Dữ Liệu & Phân Phối Lớp

150,500



mẫu | 25% Malignant (Ác tính)

- Biến số thực (6): Age, TSH_Level, T3_Level, T4_Level, Nodule_Size
- Biến phân loại (10): Gender, Country, Family_History
- Đặc điểm: Mất cân bằng lớp (Class Imbalance) tự nhiên







Phân Tích Khám Phá (EDA)

- Trung bình TSH_Level: Malignant (4.15) > Benign (2.05)
- Tương quan tuyến tính (r):
 - TSH_Level: $r = 0.52$ (Tương quan mạnh nhất)
 - Age: $r = -0.05$ (Tương quan yếu)



Định Lý Giới Hạn Trung Tâm (CLT)


- Điều kiện CLT: $n \geq 30$
→ Phân phối trung bình mẫu xấp xỉ phân phối chuẩn
- Dữ liệu thực tế:
 $n > 150,000 \gg 30$
- Kết luận: Sai số ngẫu nhiên cực thấp, các ước lượng hội tụ sát giá trị thực



Kiểm Định A/B (Permutation Test)

Biến	Mean Malignant	Mean Benign	Diff	p-value	Kết luận
TSH_Level	4.15	2.05	2.10	0.0000	Bác bỏ H_0
T3_Level	3.65	2.40	1.25	0.0000	Bác bỏ H_0

- Mô phỏng: Xáo trộn nhãn (Shuffling) 1,000 vòng lặp
- Kết quả: p-value = 0.0000
- Kết luận: Chênh lệch thực sự tồn tại, không do ngẫu nhiên



Ước Lượng Khoảng Tin Cây (Bootstrapping)

CI 95% Benign (TSH):
[2.03, 2.07]

CI 95% Malignant (TSH):
[4.12, 4.18]





- Mô phỏng: Lấy mẫu có hoàn lại 1,000 lần
- Độ rộng CI rất hẹp do n lớn
- Kết luận: Hai khoảng tin cậy không giao nhau

Phân Tích Hồi Quy Tuyến Tính (Linear Regression)

$$P(\text{Malignant}) = 0.15 \times \text{TSH_Level} + 0.05$$
$$R^2 = 0.27$$

- Hồi quy đơn biến (TSH_Level)
- Phân tích phần dư (Residuals): Phân tán ngẫu nhiên, không có pattern
- Kết luận: Mô hình tuyến tính là phương pháp tiếp cận phù hợp



Phân Lớp Láng Giềng Gần Nhất (k-NN)

- Tập dữ liệu: Train (80%) / Test (20%)
- Siêu tham số: $k = 7$
- Chỉ số đánh giá:
 - **Accuracy** (Tổng thể): **82%**
 - **Recall** (Malignant): **68%**


Diagnostic Card

Ví dụ minh họa: Bệnh nhân X

Chỉ số: TSH = 4.5, T3 = 3.9

Truy xuất thuật toán: 5/7 láng giềng gần nhất là Malignant

Kết quả: **CẢNH BÁO NGUY CƠ CAO**



Tổng Kết & Định Hướng Phân Tích

01

Khám phá

- TSH, T3 có sức mạnh chẩn đoán cao, áp đảo yếu tố nhân khẩu.
- Chênh lệch sinh học là thực tế, $p\text{-value} = 0$ (Permutation test).

02

Mô hình

- k-NN ($k=7$) đạt Accuracy 82%, Recall 68%.
- Khả năng ứng dụng cao trong sàng lọc lâm sàng bước đầu.

03

Hạn chế & Mở rộng

- Chi phí tính toán của k-NN quá lớn trên tập dữ liệu 150,000 dòng.
- Cần thu thập thêm mẫu thực tế của bệnh nhân Malignant để xử lý mất cân bằng lớp (cải thiện Recall).